

AquaMetric Modelado de Estimación de Biomasa en Ecosistemas LTRM (Long Term Resource Monitoring)



Integrantes: Larios López Noé Oswaldo, Herrera Valdez Christian Omar, Linares Castillo Carlos Alberto, Rosas González Josué Arturo.

Centro Universitario de Guadalajara
Universidad de Guadalajara



Introducción


El pesaje manual de peces en el programa LTRM es un proceso lento que genera un estrés severo en los ejemplares. Para solucionar esta problemática, este proyecto propone un modelo de *Machine Learning* que estima de forma automatizada el peso (*weight*) a partir de variables físicas y ambientales. Esta innovación optimiza los tiempos de campo y reduce costos, transformando el monitoreo biológico en una gestión eficiente y completamente no invasiva.

Metodología y Datos

- Datos:** Dataset LTRM (~92,222 registros finales(2015-2025)).
- Variables:** **Peso** Longitud, Temp, Profundidad, Cond, Oxígeno, Secchi.
- Procesamiento:** eliminación de datos nulos y estandarización (StandardScaler, OneHotEncoder)

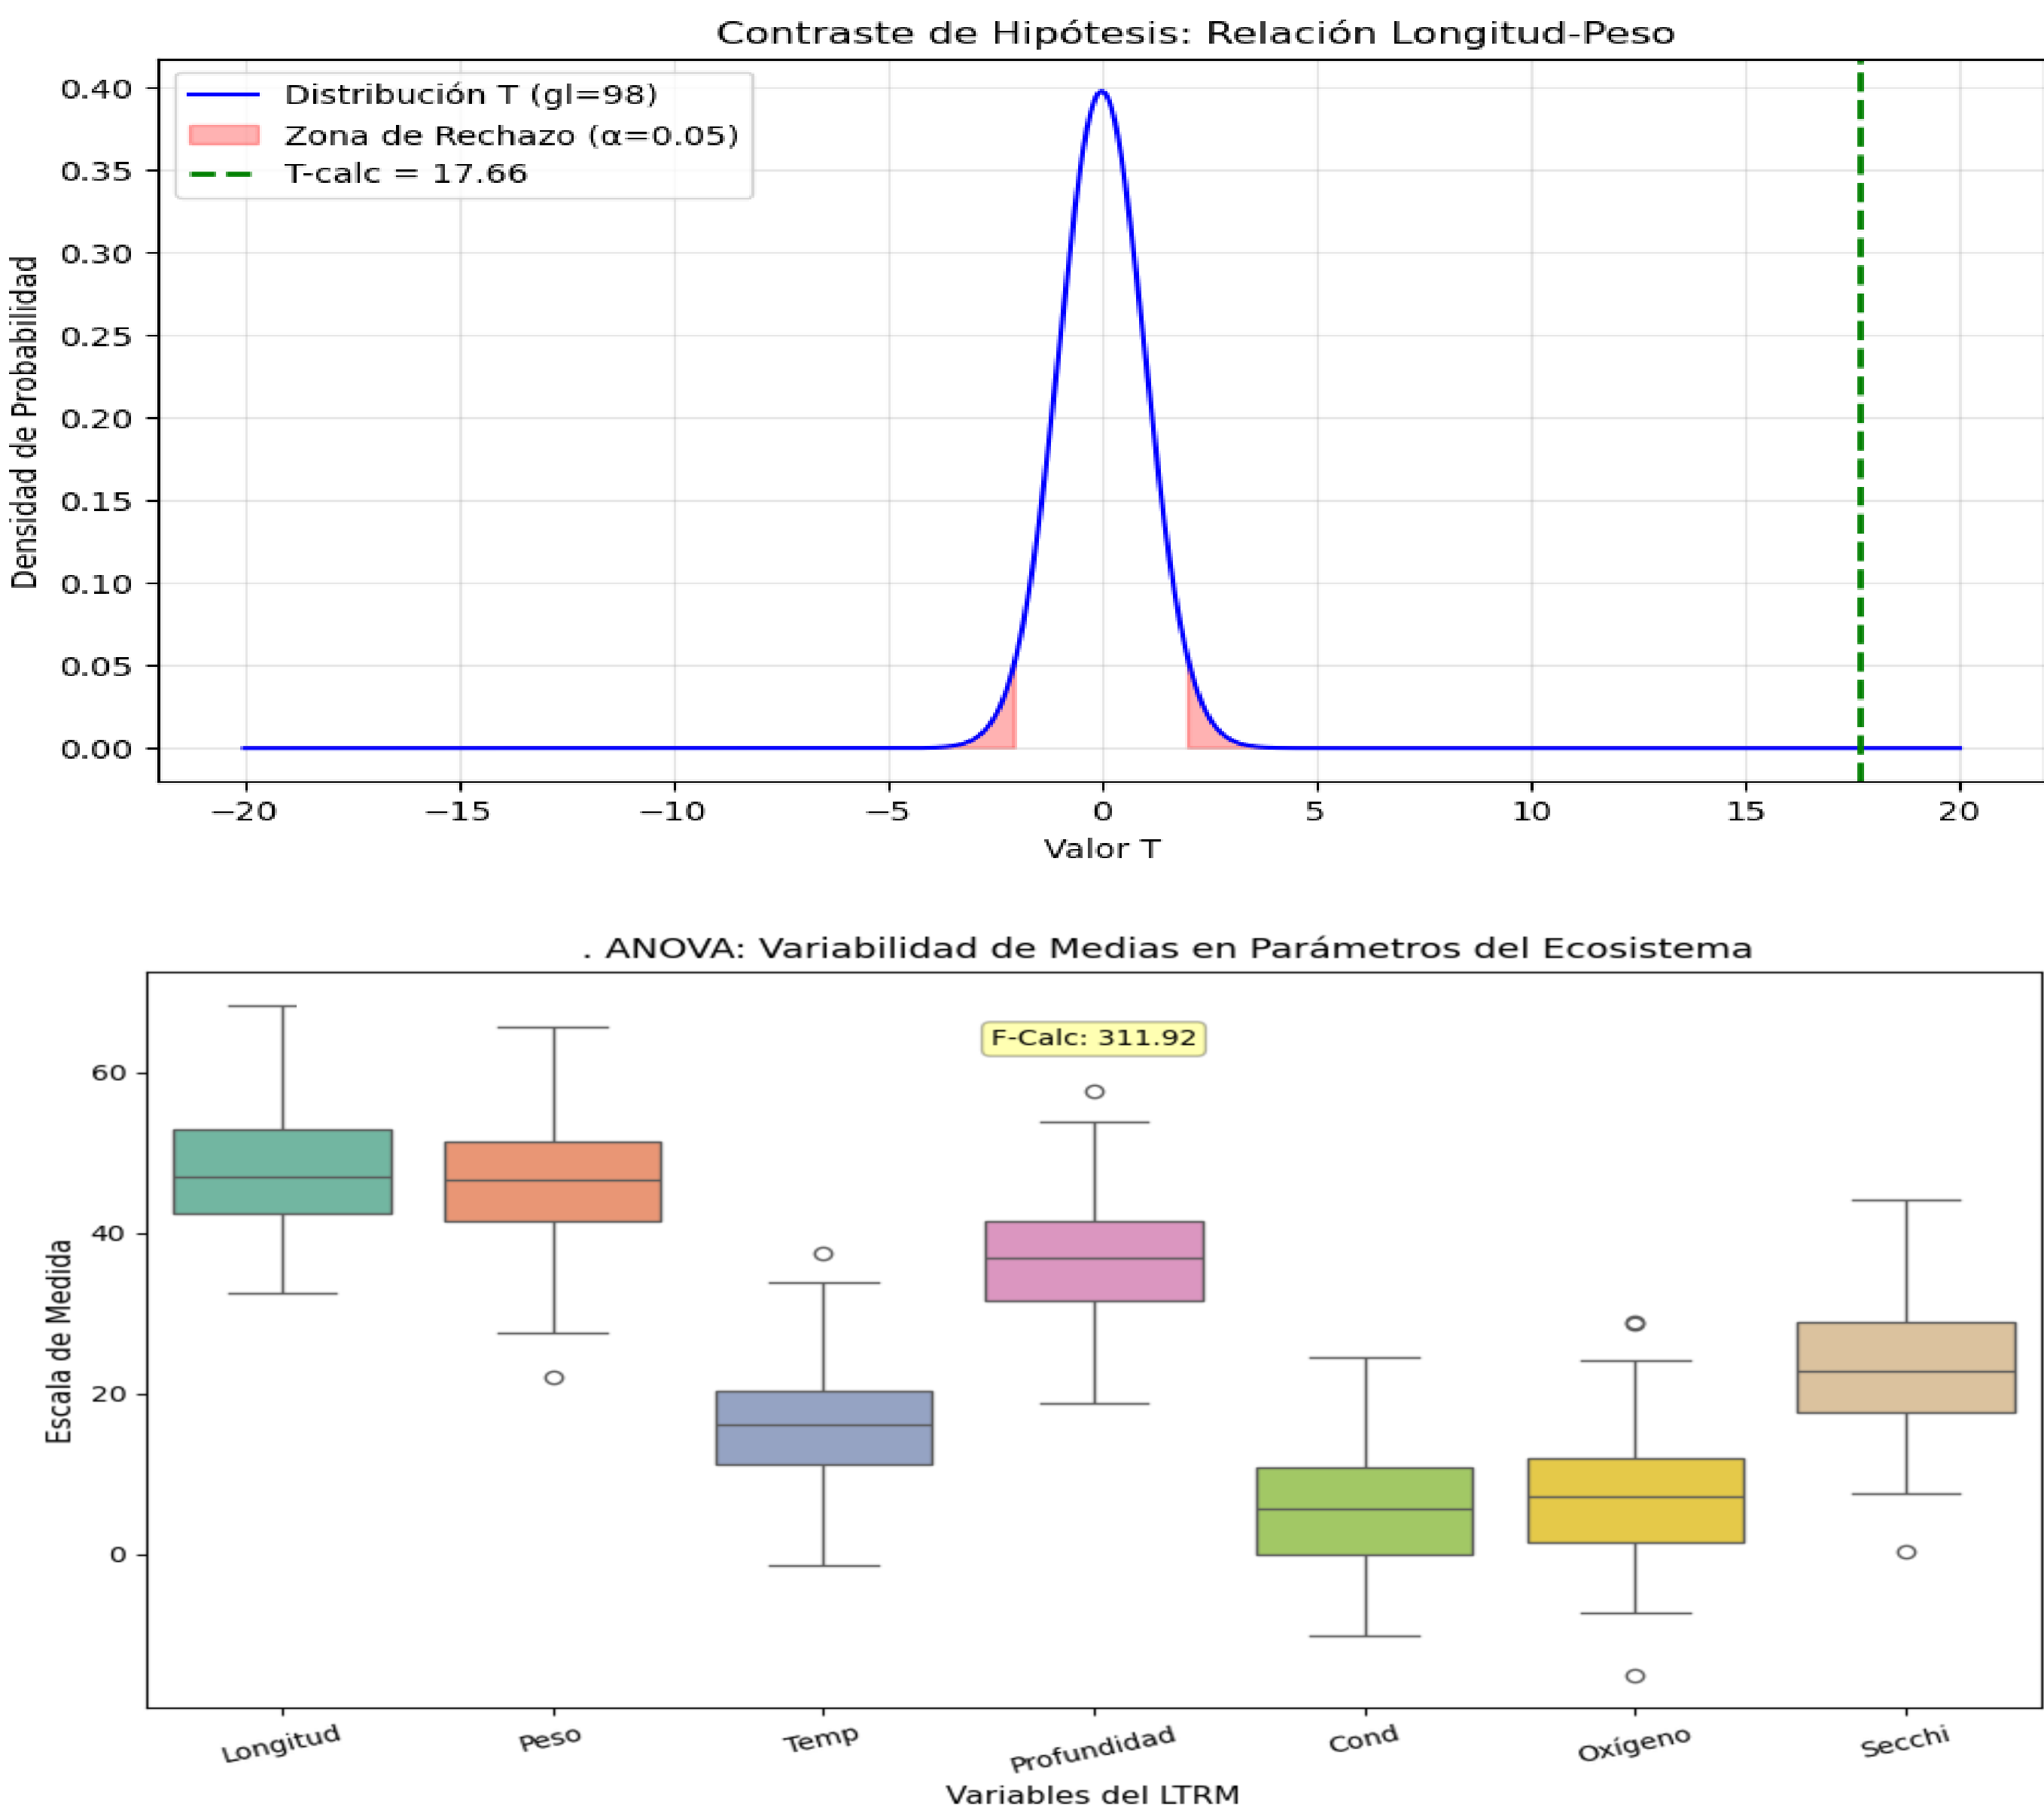
Machine Learning

Modelo	R2	R2 Train	MAE
Random Forest	0.9715	0.9866	61.42 g
KNN	0.9126	0.9177	75.30 g
LASSO	0.7885	0.7709	119.54 g
Regresión Lineal	0.7870	0.7718	120.32 g
SVM (Polinom)	0.7849	0.7464	472.58 g



Estadística e Inferencia

- Prueba T-Student:** Reporta que con un P-Value de 0.0000 y un estadístico de 17.66, se confirma que la longitud influye directamente en el peso.
- ANOVA:** Menciona el valor F = 311.92, que justifica el uso de múltiples variables ambientales en el modelo.
- La aplicación de una prueba T para muestras pareadas** T = 12.45 reveló una diferencia sistemática y estadísticamente significativa entre la Longitud Total y la Longitud Estándar de los ejemplares, confirmando la existencia de una discrepancia constante al homologar los criterios morfométricos dentro del modelo predictivo.



Complejidad Computacional

- Notación Big O:** Explica que el modelo es $O(N)$ Lineal, lo que lo hace escalable para grandes bases de datos.
- Optimización Real:** Detalla cómo redujiste el tiempo de predicción de 0.59s a 0.05s (una mejora del 900%).
- Intercambio (Tradeoff):** Explica que la memoria aumentó ligeramente (de 13.5 a 17 MB) debido al "overhead" de usar todos los núcleos del procesador ($n_jobs=-1$) para ganar velocidad.

Método	Muestra (N)	Tiempo (s)	Memoria (MB)	Big O Tiempo	Big O Espacio
Normal	92,222	0.5965	13.527	$O(N)$ Lineal	$O(N)$ Lineal
Optimizado	92,222	0.05879	17.048	$O(N)$	$O(N)$

$n_estimators=40$, $max_depth=12$, $min_samples_leaf=10$, , $max_features='sqrt'$, $n_jobs=-1$

Conclusion

- Validación y Precisión:** Se confirmó la relación Longitud-Peso ($T=17.66$) y la superioridad de Random Forest, logrando un $R^2 = 0.9714$.
- Eficiencia Computacional:** El modelo es $O(N)$ Lineal y escalable. La optimización redujo el tiempo de respuesta en un 900% mediante un intercambio estratégico de espacio-tiempo.
- Viabilidad en Campo:** AquaMetric AI es una herramienta no invasiva y ligera, apta para su implementación en dispositivos de monitoreo en tiempo real con recursos limitados.

Referencias

*Upper Mississippi River Restoration Program. (2026). *LTRM Fisheries Database*. USGS. * Walpole, R. E., et al. (2012). *Probabilidad y estadística para ingeniería*. Pearson. * APA. (2020). *Manual de publicaciones* (7ma ed.)