

UNIVERSIDAD DE GUADALAJARA CENTRO UNIVERSITARIO DE GUADALAJARA



Reporte Técnico: Análisis de Complejidad y Optimización modelo Random Forest

Materia: Complejidad Computacional

Alumnos:

Herrera Valdez Christian Omar
Larios Lopez Noe Oswaldo
Linares Castillo Carlos Alberto
Rosas Gonzales Josué Arturo

Maestro
Marco Antonio Cisnero

1. Introducción y Selección del Modelo

El presente documento detalla el análisis de complejidad del algoritmo **Random Forest**, aplicado al proyecto *AquaMetric AI* para la estimación de biomasa. Se realizó una inspección profunda del código fuente de la clase base `ForestClassifier` de Scikit-Learn para identificar los cuellos de botella en los métodos de predicción y acumulación de probabilidades.

2. Metodología de Preparación de Datos

Se trabajó con un conjunto de datos robusto de **92,222 registros** (dataset LTRM). Las fases de preparación incluyeron:

- **Limpieza:** Eliminación de registros duplicados y gestión de valores nulos en variables críticas (longitud, temperatura, profundidad, etc.).
- **Escalamiento:** Uso de `StandardScaler` para normalizar las características, asegurando que las mediciones de tiempo de CPU no se vieran sesgadas por magnitudes de datos heterogéneas.

3. Análisis de Complejidad (Big O)

Utilizando un sistema de detección automática de complejidad, se evaluó el comportamiento del modelo frente a diferentes tamaños de muestra (N). Los resultados confirmaron una naturaleza lineal:

Método	Muestra (N)	Tiempo (s)	Memoria (MB)	Big O Tiempo	Big O Espacio
Normal	92,222	0.5965	13.527	O(N) - Lineal	O(N) - Lineal
Optimizado	92,222	0.05879	17.048	O(N) - Lineal	O(N) - Lineal

Este comportamiento indica que el sistema escala de manera eficiente, manteniendo un crecimiento proporcional de recursos conforme aumenta el volumen de información.

4. Optimización de la Complejidad

Aunque la familia del Big O se mantuvo lineal ($O(N)$), se realizó una optimización de las constantes computacionales para mejorar el rendimiento en tiempo real. Los ajustes incluyeron:

- **Reducción de Árboles ($n_estimators=40$):** Menor carga en el bucle de procesamiento paralelo.
- **Control de Profundidad ($max_depth=10$) y Poda Estricta:** Reducción del número total de nodos para agilizar el recorrido.
- **Análisis del Consumo de Memoria:** Se observó un incremento ligero en la RAM (de 13.52 MB a 17.04 MB). Este fenómeno se identifica como un **Intercambio Espacio-Tiempo**: el modelo utiliza estructuras de datos adicionales y búferes de ejecución paralela para alcanzar una velocidad de respuesta superior. El "overhead" generado por la gestión de hilos mediante $n_jobs=-1$ permite que el tiempo de ejecución se reduzca en un 900%, priorizando la latencia sobre el almacenamiento volátil.

5. Conclusión General

El proyecto AquaMetric AI demuestra que la optimización basada en el análisis de complejidad permite construir modelos de Machine Learning computacionalmente responsables. La determinación de una complejidad $O(N)$ con una constante optimizada asegura que el sistema sea apto para su implementación en hardware con recursos limitados.

Se concluye que el ligero aumento en el uso de memoria RAM es un costo técnico aceptable y planeado, derivado de la paralelización y la optimización de procesos internos para maximizar la velocidad de predicción. Esta estrategia garantiza que

el sistema pueda escalar eficientemente conforme aumenten los datos del ecosistema LTRM, cumpliendo con los estándares de eficiencia. Este incremento de memoria es evidencia de una optimización de rendimiento activa, donde se decidió que 3.5 MB adicionales de RAM son un precio justo por ganar medio segundo de tiempo de respuesta por cada ciclo de predicción masiva.