

Universidad de Guadalajara CENTRO UNIVERSITARIO DE GUADALAJARA



Reporte de Proyecto Final: Predicción de Peso en Biomasa Íctica

Materia: Introducción al Machine Learning e Inferencia Bayesiana

Alumnos:

Herrera Valdez Christian Omar

Larios Lopez Noe Oswaldo

Linares Castillo Carlos Alberto

Rosas Gonzales Josué Arturo

Maestro

Toledano Juarez Iván Alejandro

1. Introducción y Objetivo del Proyecto

El presente trabajo desarrolla un análisis de regresión sobre el dataset `lrm_fish_data.csv`. El objetivo principal es construir y evaluar diversos modelos de aprendizaje supervisado capaces de predecir el peso (weight) de los peces a partir de variables morfológicas y condiciones ambientales del entorno.

2. Preprocesamiento y Limpieza de Datos

El dataset original constaba de 466,683 registros y 85 columnas. El proceso de limpieza fue el siguiente:

- Eliminación de redundancias: Se eliminaron registros duplicados para evitar sesgos.
- Selección de Variables: Se filtraron 7 variables predictoras con relevancia biológica: `fishcode` (especie), `length` (longitud), `temp` (temperatura), `depth` (profundidad), `cond` (conductividad), `do` (oxígeno disuelto) y `secchi` (transparencia).
- Tratamiento de Nulos: Se eliminaron todas las filas con valores faltantes en la variable objetivo (weight) y en las características.
- Dataset Final: El volumen de datos útil para el entrenamiento quedó fijado en 92,222 muestras.

3. Ingeniería de Características y Normalización

Para el tratamiento de los datos antes del modelado, se utilizó un `ColumnTransformer` que aplicó:

1. `StandardScaler`: Para las variables numéricas, asegurando que todas tuvieran media 0 y varianza 1. Esto es crítico para algoritmos basados en distancias como KNN y SVM.
2. `OneHotEncoder`: Para la variable categórica `fishcode`, permitiendo al modelo interpretar matemáticamente las diferencias entre especies sin establecer una jerarquía artificial.

4. Metodología de Validación

Se aplicó un esquema de validación Hold-out con una división de 80% para entrenamiento (73,777 muestras) y 20% para validación (18,445 muestras). Se utilizó una semilla aleatoria (random_state=42) para garantizar la reproducibilidad de los resultados.

5. Resultados de los Modelos de Regresión

A continuación, se presentan las métricas de rendimiento obtenidas en el conjunto de validación:

Modelo	R2 (Precisión)	MAE (Error Abs.)	RMSE (Raíz Error Cuadrático)
Random Forest	0.9714	61.53 g	194.29 g
KNN (k=5)	0.9125	112.45 g	340.08 g
LASSO	0.7885	311.22 g	528.85 g
Regresión Lineal	0.7870	312.09 g	530.79 g
SVM (SVR)	0.0510	472.58 g	1120.34 g

6. Análisis e Interpretación de Resultados

En esta fase, se evaluó la capacidad de cinco algoritmos para modelar la compleja relación entre las variables morfológicas, las condiciones ambientales y el peso de los peces. A continuación, se detalla la función de cada modelo y la interpretación técnica de sus resultados:

A. Random Forest (Bosque Aleatorio) - Modelo Superior

- **Uso y utilidad:** Se empleó como un modelo de ensamble para capturar relaciones no lineales y reducir la varianza mediante la combinación de múltiples árboles de decisión.
- **Interpretación:** Fue el ganador definitivo, superando ampliamente a los demás con un R^2 de 0.97. Esto indica que el modelo logra explicar el 97% de la variabilidad del peso de los peces. Además, su error promedio (MAE) de

solo 61.53 gramos demuestra una excelente capacidad de generalización frente a datos no vistos durante el entrenamiento.

- Importancia de Variables: Gracias a la estructura de este modelo, se confirmó que la longitud (num__length) es el factor crítico, aportando más del 84% de la importancia en la predicción. Las especies específicas (fishcode) ocupan los siguientes lugares de relevancia biológica.
 - SNGR (Sauger): Ocupa el segundo lugar de importancia general (después de la longitud) con un valor de impacto de aproximadamente 0.0366.
 - LNGR (Longnose Gar): Ocupa el tercer lugar de importancia, muy cerca de la anterior, con un valor de 0.0361.
 - LKSG (Lake Sturgeon): Se sitúa en el cuarto lugar de relevancia biológica para el modelo, con un impacto de 0.0167.
 - CARP (Common Carp): Es la quinta variable más influyente, con un valor de 0.0105.
 - SMBF (Smallmouth Buffalo): Cierra el grupo de las especies con mayor peso predictivo con un valor de 0.0092.

B. KNN (K-Nearest Neighbors)

- Uso y utilidad: Se utilizó para identificar patrones basados en la similitud local (vecindad) entre los ejemplares.
- Interpretación: Este modelo sirvió para demostrar que peces con características físicas y ambientales similares tienen pesos muy parecidos, logrando un notable R^2 de 0.9125. Es el segundo mejor modelo, aunque con un error promedio (112.45 g) casi el doble que el de Random Forest.

C. LASSO (Least Absolute Shrinkage and Selection Operator)

- Uso y utilidad: Se aplicó para introducir regularización, ayudando a simplificar el modelo y evitar el sobreajuste al penalizar variables menos relevantes.
- Interpretación: Logró un R^2 de 0.7885, permitiendo una ligera mejora sobre la regresión base al ajustar los coeficientes de las variables ambientales con menor impacto predictivo.

D. Regresión Lineal Clásica

- Uso y utilidad: Funcionó como el *baseline* o punto de referencia inicial para medir la complejidad del problema.

- Interpretación: Obtuvo un R^2 de 0.7870. Este resultado indica que, si bien una gran parte del peso tiene una relación lineal directa con la longitud, el modelo base es incapaz de capturar los matices biológicos más complejos que sí detecta el bosque aleatorio.

E. SVM / SVR (Support Vector Regression) - Desempeño Deficiente

- Uso y utilidad: Se empleó con un kernel radial (RBF) para intentar encontrar un hiperplano de separación en un espacio de mayor dimensión.
- Interpretación: Mostró el rendimiento más bajo con un R^2 de apenas 0.0510 y una alta carga computacional. Esto sugiere que, con los parámetros por defecto, el modelo no pudo converger ni capturar la complejidad de la relación en este dataset masivo de más de 90,000 registros, resultando en un error promedio muy elevado de 472.58 g.

7. Conclusiones

El proyecto demuestra que es posible estimar con precisión el peso de los peces utilizando técnicas de Machine Learning. El uso de Random Forest resulta la opción más viable para aplicaciones reales de monitoreo biológico, dadas su precisión y capacidad para manejar variables categóricas y numéricas simultáneamente.

DICCIÓN DE BIOMASA ÍCTICA

Modelado de Regresión y Evaluación de Factores Ambientales (LTRM)

Herrera Valdez Christian Omar, Larios Lopez Noe Oswaldo, Linares Castillo

Carlos Alberto, Rosas Gonzales Josué Arturo

Centro Universitario de Guadalajara (UdeG) | Mayo 2026

1. Introducción & Objetivo

La estimación de biomasa es crucial para la gestión sostenible. Las mediciones manuales son lentas; predecirlas mediante variables externas optimiza el monitoreo. **Objetivo:** Desarrollar un modelo de aprendizaje supervisado para predecir el peso (weight) con alta precisión.

2. Metodología

- Datos:** Dataset LTRM (~92,222 registros finales(2015-2025).
 - Variables:** **Peso** Longitud, Temp, Profundidad, Cond, Oxígeno, Secchi.
- Procesamiento:** eliminación de datos nulos y estandarización (StandardScaler, OneHotEncoder)

3. Inferencia Estadística

Regresión Lineal:

Estadístico T: **17.66** | P-value: **0.0000**.

Se rechaza H_0 : La longitud es un predictor significativo.

ANOVA Multivariable:

Estadístico F: **311.92** | F-Crítico: **~2.10**.

Diferencia significativa en escalas ambientales detectada.

4. Resultados de Machine Learning

Modelo	R^2	R^2 Train	MAE
Random Forest	0.9715	0.9866	61.42 g
KNN	0.9126	0.9177	75.30 g
LASSO	0.7885	0.7709	119.54 g
Regresión Lineal	0.7870	0.7718	120.32 g
SVM (Polinom)	0.7849	0.7464	472.58 g

5. Discusión & Conclusiones

Superioridad de Random Forest: Mejor ajuste debido a su capacidad para manejar la no linealidad longitud-peso.

Conclusión

El proyecto demuestra que Random Forest es el modelo óptimo ($R^2 = 0.9714$) para predecir biomasa con un error de ± 61.52 g. La longitud es la variable crítica predicti