

UNIVERSIDAD DE GUADALAJARA

CENTRO UNIVERSITARIO DE GUADALAJARA



Reporte de Proyecto Final: Predicción de Peso en Biomasa Íctica

Materia: Matemáticas aplicada a la ciencia de datos
(Explicación de dos modelos)

Alumnos:

Herrera Valdez Christian Omar
Larios Lopez Noe Oswaldo
Linares Castillo Carlos Alberto
Rosas Gonzales Josué Arturo

Maestro

Toledano Juarez Iván Alejandro

Parte 1

Arboles de decisiones

Formulación Matemática del Modelo

El Random Forest es un predictor de ensamble que consiste en una colección de B árboles de decisión $\{T_1(x), T_2(x), \dots, T_B(x)\}$.

Para una tarea de regresión como la de biomasa, la predicción final $\hat{y}$ para un pez con características x es el promedio aritmético de las predicciones de todos los árboles individuales:

$$\hat{f}_{rf}^B(x) = \frac{1}{B} \sum_{b=1}^B T_b(x)$$

Variables: x representa el vector de entrada (Longitud, Temperatura, etc.).

Parámetros: Incluye el número de árboles (B), la profundidad máxima de cada árbol y el número de variables consideradas en cada corte (m).

Supuesto: Asume que aunque los árboles individuales puedan cometer errores (tener alta varianza), sus errores no están correlacionados y se cancelarán al promediarlos.

Función de Costo.

- A diferencia de un modelo simple, el Random Forest no minimiza una única función de costo global, sino que cada árbol T_b minimiza de forma independiente el Error Cuadrático Medio (MSE) en su propia muestra de datos:

$$MSE_b = \frac{1}{n} \sum_{i \in \theta_b} (y_i - \hat{y}_{i,b})^2$$

Donde T_b es el subconjunto de datos "Bootstrap" (una muestra aleatoria con reemplazo) asignado al árbol b .

Método de optimización.

- Bagging (Bootstrap Aggregating): Se crean B muestras aleatorias del dataset original. Esto permite que cada árbol vea una "versión" ligeramente diferente de la realidad, aumentando la diversidad del bosque.
- Feature Randomness (Aleatoriedad de Atributos): En cada nodo de cada árbol, el algoritmo no busca entre todas las variables (p). En su lugar, selecciona un subconjunto aleatorio de variables ($m \approx p/3$ para regresión) y elige la mejor de ese grupo. Esto desacopla los árboles y evita que una variable muy fuerte (como la longitud) domine a todas las demás.

Propiedades matemáticas relevantes.

- Reducción de Varianza: Es su propiedad más potente. Si los árboles están poco correlacionados, la varianza del promedio es σ^2/B . Al aumentar B, el error del modelo se estabiliza.
- Error Out-of-Bag (OOB): Matemáticamente, cada árbol deja fuera cerca del 36.8% de los datos. Estos datos "no vistos" se usan para validar el modelo internamente sin necesidad de un set de validación externo.
- Convergencia: Según la Ley de los Grandes Números, el Random Forest no sufre de sobreajuste (overfitting) solo por agregar más árboles; el error de generalización converge a un límite.

Pros y contras del modelo desde una perspectiva matemática.

Pros:

- Estabilidad: Es mucho menos sensible a cambios pequeños en los datos que un solo árbol.
- Manejo de No-Linealidad: Captura relaciones complejas entre el ecosistema y el peso sin necesidad de transformar las variables (como sacar logaritmos).
- Importancia de Variables: Permite calcular matemáticamente qué tanto contribuye cada variable (ej. Oxígeno vs. Temperatura) a la reducción total del MSE.

Contras:

- Costo Computacional: Requiere mucho más memoria y tiempo de procesamiento que un árbol simple.
- Pérdida de Interpretabilidad: Ya no puedes "leer" el modelo fácilmente; se convierte en una estructura matemática compleja (Caja Negra).

Argumento teórico sobre por qué ese modelo es adecuado para el problema elegido.

- Multivariabilidad Ambiental: Los ecosistemas son ruidosos. Un solo árbol podría confundir ruido con patrones; el Random Forest promedia ese ruido para encontrar la verdadera señal biológica.
- Variables Altamente Correlacionadas: En biología, la longitud total y la longitud estándar están muy correlacionadas. El Random Forest maneja esto mejor que la regresión lineal gracias a la selección aleatoria de atributos, evitando problemas de multicolinealidad.

K-Nearest Neighbors (K-NN)

Formulación Matemática del Modelo

El modelo k-NN es un algoritmo no paramétrico y de aprendizaje basado en instancias. No genera una ecuación explícita para todo el dataset, sino que estima el valor de salida localmente.

Para un pez con características x , el modelo identifica un conjunto $N_K(x)$ que contiene los k puntos más cercanos en el dataset de entrenamiento. La predicción del peso $\hat{y}$ es la media aritmética de las etiquetas de esos vecinos:

$$\hat{y}(x) = \frac{1}{k} \sum_{x_i \in N_K(x)} y_i$$

- Variables: x es el vector de entrada (medidas morfológicas y ambientales).
- Parámetros: El valor de k (hiperparámetro) y la métrica de distancia elegida.

- Supuesto: La Hipótesis de Continuidad, que dicta que puntos cercanos en el espacio de características deben tener valores de salida similares.

Función de Costo

A diferencia de otros modelos, k-NN no tiene una función de costo que se minimice durante una fase de "entrenamiento" (ya que no aprende pesos β o cortes de árbol). Sin embargo, el criterio de selección del modelo se basa en minimizar el Error Cuadrático Medio (MSE) sobre el conjunto de prueba o mediante validación cruzada:

$$J(k) = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_{i,(k)})^2$$

El objetivo matemático es encontrar el k óptimo que balancee el sesgo y la varianza.

Método de Optimización

Para optimizar la velocidad de búsqueda en espacios de alta dimensión, se utilizan estructuras de datos avanzadas como:

- KD-Trees: Particionan el espacio de manera jerárquica.
- Ball Trees: es una estructura de datos de particionamiento espacial que organiza los puntos en "bolas" (hiperesferas) jerárquicas.

Propiedades Matemáticas Relevantes

- Métrica de Distancia: Utiliza usualmente la Distancia Euclidiana (L_2 norm), la cual define la geometría del modelo:

$$d(x, x_i) = \sqrt{\sum_{j=1}^p (x_j - x_{ij})^2}$$

- Sensibilidad a la Escala: Debido a la fórmula anterior, si una variable tiene un rango mayor que otra, la primera dominará la distancia. Por ello, la normalización es un requisito matemático estricto.

- Maldición de la Dimensionalidad: A medida que agregas más variables ambientales, el "espacio" se vuelve tan vasto que todos los puntos parecen estar lejos unos de otros, degradando la efectividad de la distancia.

Pros y Contras (Perspectiva Matemática)

- **Pros:**
 - Adaptabilidad Local: Puede capturar patrones extremadamente complejos y no lineales que ni siquiera un bosque aleatorio vería.
 - Sin Supuestos de Distribución: No requiere que los datos sean normales o lineales.
 - Actualización Sencilla: Solo necesitas agregar nuevos datos de peces al sistema para que el modelo "aprenda".
- **Contras:**
 - Costo de Memoria: Debe guardar todo el dataset en RAM para funcionar.
 - Inferencia Lenta: Predecir el peso de un pez nuevo requiere compararlo contra todos los miles de registros previos.
 - Sensible a Outliers: Un vecino con datos erróneos pesa significativamente en el promedio final (especialmente con k pequeños).

Argumento teórico sobre por qué ese modelo es adecuado para el problema elegido.

- Firma Específica por Especie: Los peces de una misma especie que viven en condiciones similares tienden a agruparse en regiones muy específicas del espacio matemático. El k -NN explota esta "vecindad biológica" de forma natural.
- Modelado de Nichos: Si el dataset tiene especies poco comunes (pocos datos), el k -NN puede predecir su peso con precisión simplemente buscando a los pocos individuos similares que existan, sin intentar crear una regla general que los ignore.

PARTE II

Dataset: *U.S. Army Corps of Engineers - Long Term Resource Monitoring (LTRM) Fish Component*.


- Origen: Kaggle / Registros gubernamentales de EE. UU.
- Contexto: Un conjunto de datos masivo que documenta la abundancia y características físicas de peces en ecosistemas fluviales (Mississippi e Illinois) desde 1993 a 2025.

Describir brevemente las variables

Para los modelos implementados, seleccionamos las siguientes columnas del dataset final (92,222 registros):

- Variables Predictoras (X):
 - length: Longitud total del espécimen (variable continua, fundamental para la biometría).
 - temp: Temperatura del agua (factor metabólico).
 - Do: (Oxígeno Disuelto): Indicador de calidad del hábitat.
 - cond: Conductividad del agua.
 - fishcode: Identificador de la especie (convertido mediante *Label Encoding*).
 - Depth: Profundidad del cuerpo de agua en la estación de muestreo
 - Secchi: Medida de la transparencia o turbidez del agua.
- Variable Objetivo (y):
 - weight: Peso del pez (Biomasa), que es el valor que buscamos predecir.
- Procesamiento
Se utilizó LabelEncoder para la columna de especies y standardScaler para normalizar las variables ambientales, asegurando que KNN no se sesgara por las diferentes unidades (ej. mm vs °C).

Generar algunas gráficas o tablas básicas



- Mostrar el resultado principal del modelo (predicciones, clusters, componentes, etc.)

Modelo	MAE	RMSE	R ² (Validación)
Random Forest	61.538266	194.296495	0.971460
KNN	112.453674	340.087354	0.912561
LASSO	311.221426	528.850511	0.788559
Regresión Lineal	312.096517	530.796793	0.787000
SVM (Poli)	256.660522	533.369506	0.784930

- Conectar estos resultados con la explicación teórica

El uso de **Random Forest** es matemáticamente apropiado para este dataset porque:

1. Maneja la **no-linealidad** natural entre el ambiente y el peso.
2. Es robusto ante los **valores atípicos** detectados en el análisis exploratorio
3. La técnica de **Bagging** permite que el error de generalización sea bajo, asegurando que el modelo funcione con nuevos datos del LTRM (Long Term Resource Monitoring).